

Título Descriptivo del Proyecto de Inteligencia Artificial

Subtítulo: enfoque metodológico y aplicación específica

Juan Esteban Trujillo Montes

jetrujillm@eafit.edu.co

Andrés Péres Qunchía

aperezq@eafit.edu.co

Sahian Salome Gutierrez Ossa

ssgutierro@eafit.edu.co

Escuela de Ciencias Aplicadas e Ingeniería . Universidad EAFIT

Curso: Inteligencia Artificial . Semestre 2026-1

Entrega: 19–22 de mayo de 2026

Repositorio: <https://github.com/JuanTrujilloM/startup-success-llm.git>

Resumen

Contexto: La predicción del éxito de startups es un problema de alto impacto para inversores y ecosistemas de emprendimiento, donde decidir qué empresas financiar implica riesgo significativo ante la escasez de señales objetivas en etapas tempranas.

Objetivo: Desarrollar un sistema que clasifique startups como exitosas (*acquired*) o fracasadas (*closed*) y genere explicaciones comprensibles en lenguaje natural para cada predicción.

Método: Se entrenó un clasificador XGBoost sobre 923 startups del dataset *Startup Success Prediction* (Kaggle), aplicando SMOTE para balancear clases y StandardScaler para normalización. La explicabilidad se implementó mediante valores SHAP, cuyos factores más influyentes se pasan como contexto a un LLM (Llama-3.1-8b vía Groq) para generar recomendaciones en lenguaje natural dirigidas al inversor.

Resultados: El modelo XGBoost alcanzó AUC-ROC = 0.82 y F1 = 0.83 en el conjunto de prueba, superando al baseline de regresión logística (AUC = 0.79) en 3.14 puntos porcentuales.

Conclusión: La combinación de XGBoost con explicabilidad SHAP y generación de lenguaje natural permite no solo predecir el éxito de una startup sino también justificar la decisión en términos comprensibles para un inversor no técnico.

Palabras clave: Machine Learning, XGBoost, SMOTE, SHAP, Explicabilidad algorítmica, Modelos de lenguaje de gran escala (LLM), Predicción de éxito empresarial, Clasificación binaria desbalanceada, Groq API, Startups.

1. Introducción

El ecosistema global de startups enfrenta una tasa de fracaso superior al 90 % en sus primeros años de opera-

ción, lo que convierte la identificación temprana de empresas con alto potencial en una necesidad crítica para inversores, fondos de capital de riesgo y aceleradoras. Tradicionalmente, estas decisiones se han basado en criterios subjetivos como la experiencia del equipo fundador o la intuición del inversor, dejando de lado patrones estadísticos que pueden extraerse de datos históricos de financiación, crecimiento y red de contactos.

En este contexto, el aprendizaje automático ofrece una alternativa objetiva y escalable. Sin embargo, uno de los principales obstáculos para su adopción en entornos de inversión es la falta de interpretabilidad: un modelo que predice con alta precisión pero no explica su razonamiento genera desconfianza en el tomador de decisiones. Este trabajo aborda precisamente esa brecha combinando un clasificador de alto desempeño con un mecanismo de explicación en lenguaje natural.

La **pregunta de investigación** que guía este proyecto es:

“¿Puede un modelo XGBoost predecir el éxito de una startup con AUC-ROC superior a 0.80 y un LLM generar explicaciones comprensibles para inversores usando valores SHAP como contexto?”

Para responderla, se utilizó el dataset *Startup Success Prediction* disponible en Kaggle [5], que contiene 923 startups caracterizadas por 49 variables relacionadas con financiación, sector, ubicación geográfica y red de relaciones. La variable objetivo es binaria: *acquired* (éxito) o *closed* (fracaso), con una distribución de 64.7 % y 35.3 % respectivamente.

El resto del documento se organiza así: la Sección 2 presenta el análisis exploratorio de los datos, la Sección 3 describe la arquitectura del sistema, la Sección 4 detalla la metodología experimental, la Sección 5 reporta los resultados obtenidos, la Sección 6 discute las implicaciones y limitaciones, y la Sección 7 presenta las conclusiones.

2. Datos y Exploración (EDA)

2.1. Descripción del dataset

Cuadro 1: Resumen del dataset utilizado

Atributo	Descripción
Fuente	https://www.kaggle.com/datasets/manishkc06/startup-success-prediction
Registros (N)	923 startups
Features (p)	31 numéricas / 1 categórica
Variable objetivo	labels — binaria (1=acquired, 0=closed)
Desbalance	64.7 % acquired / 35.3 % closed
Tamaño	144 KB

El dataset contiene información histórica de startups principalmente estadounidenses, incluyendo variables de financiación, rondas de inversión, hitos alcanzados, red de relaciones y sector de operación.

2.2. Hallazgos del análisis exploratorio

El análisis exploratorio reveló los siguientes patrones relevantes:

- **Desbalance moderado:** la clase mayoritaria (*acquired*) representa el 64.7 % de los datos, lo que justifica aplicar SMOTE durante el preprocesamiento para evitar sesgo hacia la clase mayoritaria.
- **Predictores más fuertes:** *relationships* ($r=0.36$), *milestones* ($r=0.33$) e *is_top500* ($r=0.31$) presentan la mayor correlación positiva con el éxito, sugiriendo que la red de contactos y los hitos alcanzados son factores críticos.
- **Financiación:** las startups adquiridas tienen en promedio 2.5 rondas de financiación frente a 1.9 de las cerradas, y más del doble de relaciones registradas.
- **Inversión temprana negativa:** *has_angel* y *has_VC* correlacionan negativamente con el éxito, indicando que startups que solo reciben inversión en etapa temprana sin avanzar a rondas A/B tienden a cerrar.
- **Valores nulos:** las columnas *age_first_milestone_year* y *age_last_milestone_year* presentaron 152 nulos, imputados con 0 al corresponder a startups sin hitos registrados.




Figura 1: Distribución de clases — 597 startups acquired (64.7 %) vs. 326 closed (35.3 %).




Figura 2: Correlación de features numéricas con el éxito de la startup. *relationships* y *milestones* son los predictores más fuertes.

2.3. Preprocesamiento

A partir de los hallazgos del EDA se aplicó el siguiente pipeline de preprocesamiento:

1. **Eliminación de columnas:** se removieron 17 columnas correspondientes a identificadores, coordenadas geográficas, fechas crudas y duplicados, pasando de 49 a 32 features.
2. **Imputación:** nulos en columnas de *milestones* reemplazados por 0.
3. **Split estratificado:** división 80/20 (*random_state=42*) preservando la proporción de clases — 738 muestras para entrenamiento y 185 para prueba.
4. **Normalización:** *StandardScaler* ajustado exclusivamente sobre el conjunto de entrenamiento y aplicado al de prueba para evitar *data leakage*.
5. **SMOTE:** aplicado únicamente sobre el train set, balanceando las clases de 477/261 a 477/477. El test set conserva la distribución real.

3. Arquitectura del Sistema

El sistema propuesto integra tres componentes principales: un clasificador de machine learning, un módulo de explicabilidad y un generador de lenguaje natural. La Figura ?? ilustra el flujo completo desde los datos de entrada hasta la explicación final entregada al inversor.




Figura 3: Arquitectura del despliegue

3.1. Componentes principales

Preprocesamiento. Pipeline reproducible que incluye eliminación de columnas irrelevantes, imputación de nulos, split estratificado 80/20 con `random_state=42`, normalización con `StandardScaler` ajustado solo sobre train, y balanceo de clases con `SMOTE` únicamente sobre el conjunto de entrenamiento.

Modelo de ML. Clasificador `XGBoost` con `max_depth=4`, `n_estimators=200` y regularización L1/L2. Entrenado sobre 954 muestras balanceadas (477 por clase) y evaluado sobre 185 muestras con distribución real. Se eligió `XGBoost` por su robustez ante features de distinta escala, su capacidad de capturar interacciones no lineales entre variables de financiación y su compatibilidad nativa con `SHAP` para explicabilidad.

Explicabilidad con SHAP. Se calcularon valores `SHAP` (*SHapley Additive exPlanations*) sobre el modelo entrenado usando `TreeExplainer`, que aprovecha la estructura de árboles para un cálculo exacto y eficiente. Para cada startup se extraen los 5 factores más influyentes — con su

dirección e intensidad — que se pasan como contexto al LLM.

Componente LLM. Modelo `llama-3.1-8b-instant` accedido vía `Groq API` (gratuita). Recibe un prompt estructurado con la probabilidad de éxito predicha y los top-5 valores `SHAP` de la startup, y genera una explicación en lenguaje natural de máximo 4 oraciones dirigida a un inversor no técnico. Se utilizó `prompting zero-shot` con `temperature=0.3` para respuestas consistentes y reproducibles.

Interfaz de usuario. Aplicación web desarrollada con `Streamlit` que permite seleccionar una startup del conjunto de prueba, visualizar sus valores `SHAP` en una tabla interactiva y generar la explicación del LLM con un clic.

4. Metodología

4.1. Configuración experimental

El modelo final `XGBoost` fue entrenado con hiperparámetros conservadores, elegidos pensando en el tamaño limitado del dataset y el riesgo de sobreajuste. La Tabla 2 resume la configuración utilizada.

Cuadro 2: Hiperparámetros y configuración de entrenamiento

Parámetro	Valor
Algoritmo	XGBoost Classifier
n_estimators	200
max_depth	4
learning_rate	0.1
subsample	0.8
colsample_bytree	0.8
reg_alpha (L1)	0.1
reg_lambda (L2)	1.0
eval_metric	logloss
random_state	42
Framework	scikit-learn 1.4.2 + XGBoost 2.0.3
Hardware	CPU (Apple Silicon M-series)

La elección de `max_depth=4` responde al ratio entre muestras y features ($954/31 \approx 30:1$), donde profundidades mayores tienden a memorizar el ruido del conjunto de entrenamiento. Los parámetros `subsample` y `colsample_bytree` en 0.8 introducen aleatoriedad en cada árbol, actuando como regularización implícita, mientras que `reg_alpha` y `reg_lambda` penalizan pesos excesivos en features individuales.

4.2. Estrategia de validación

Se utilizó validación cruzada estratificada con 5 folds (`StratifiedKFold` con `shuffle=True` y

random_state=42) sobre el conjunto de entrenamiento. La estratificación garantiza que cada fold conserve la proporción de clases del conjunto original, lo cual es importante para obtener estimaciones estables en datasets de tamaño limitado.

El conjunto de prueba (185 muestras, distribución 65/35 entre *acquired* y *closed*) se mantuvo aislado durante toda la fase de modelado y solo se utilizó para la evaluación final. Esta separación estricta evita filtraciones de información y garantiza que las métricas reportadas reflejen la capacidad real de generalización del modelo.

4.3. Experimentos realizados

Se compararon dos modelos con metodología idéntica de validación:

1. **Baseline – Regresión Logística:** modelo lineal simple con `max_iter=1000`, sin regularización adicional más allá de la L2 por defecto. Sirve como punto de referencia: cualquier modelo más complejo debe justificar su uso superando esta cota.
2. **Modelo principal – XGBoost:** clasificador de gradient boosting con regularización L1/L2 y profundidad moderada. Elegido por su capacidad de capturar interacciones no lineales entre features y su compatibilidad nativa con SHAP a través de TreeExplainer.

No se realizó búsqueda exhaustiva de hiperparámetros (*grid search*) por dos razones: el tamaño del dataset limita la confiabilidad estadística de las comparaciones entre configuraciones cercanas, y el efecto de SMOTE pre-CV (descrito en la Sección 6.2) inflaría artificialmente las métricas de validación, llevando potencialmente a seleccionar parámetros sobreajustados al ruido. Se optó por una configuración conservadora y bien fundamentada teóricamente.

5. Resultados

5.1. Métricas de evaluación

La Tabla 3 muestra el desempeño en términos de AUC-ROC, precisión, recall y F1 sobre la clase positiva (*acquired*).

Cuadro 3: Comparación de modelos en el conjunto de prueba

Modelo	AUC	Prec.	Recall	F1
Baseline (LogReg)	0.7927	0.79	0.81	0.80
XGBoost (mejor)	0.8241	0.82	0.84	0.83

XGBoost supera al baseline en 3.14 puntos porcentuales de AUC-ROC, con mejoras consistentes en todas las métricas. La validación cruzada estratificada sobre el conjunto de entrenamiento reportó AUC promedio de 0.8781, lo que indica un modelo estable a través de particiones.

-2-2 **Nota:** El AUC reportado en validación cruzada (0.88) es superior al de test (0.82) debido a que SMOTE fue aplicado antes del split de CV. Las métricas en test son la referencia honesta de generalización.

5.2. Matriz de confusión y curva ROC

La Figura 4 presenta el comportamiento del modelo XGBoost en el conjunto de prueba. La matriz de confusión revela 22 falsos positivos (startups predichas como *acquired* que en realidad cerraron) y 19 falsos negativos (startups *acquired* clasificadas como *closed*).




Figura 4: Matriz de confusión y curva ROC del modelo XGBoost sobre el conjunto de prueba (AUC = 0.824).

Desde la perspectiva de un inversionista, los 22 falsos positivos representan el escenario de mayor costo: capital invertido en startups que finalmente fracasaron. Esto equivale a una tasa de error del 17.9 % sobre el total de predicciones positivas (101 verdaderos positivos + 22 falsos positivos).

5.3. Análisis de importancia de features

Se utilizó SHAP con TreeExplainer para interpretar las decisiones del modelo. La Figura 5 muestra el ranking global de features por magnitud promedio de impacto.




Figura 5: Importancia global de features según el valor absoluto promedio de los SHAP values sobre el conjunto de prueba.

Los cinco predictores más influyentes son: **relationships** (número de conexiones de la startup), **age_last_milestone_year** (recencia del último hito), **age_first_funding_year**, **funding_total_usd** e **is_otherCategory**. El número de relaciones domina con un impacto promedio aproximadamente 50 % mayor que el segundo feature más importante, lo que sugiere que el capital social y la red de contactos son los predictores más fuertes del éxito en este dataset.

5.4. Análisis cualitativo

Para evaluar la interpretabilidad del modelo a nivel de predicción individual, se analizaron tres casos representativos mediante waterfall plots. La Figura 6 muestra el caso de predicción incierta, donde fuerzas positivas y negativas se balancean casi por igual.




Figura 6: Waterfall plot de una predicción con incertidumbre alta. La startup presenta milestones recientes pero pocas relaciones, lo que produce un balance de fuerzas casi neutro.

Este tipo de descomposición permite que un inversionista entienda por qué el modelo emite una predicción específica, identificando los factores que más contribuyen tanto al éxito como al cierre. Los SHAP values resultantes se exportan en formato estructurado para alimentar el componente de generación de explicaciones en lenguaje natural.

6. Discusión

6.1. Interpretación de resultados

Los resultados obtenidos responden afirmativamente a la pregunta de investigación planteada: el modelo XG-Boost logra un AUC-ROC de 0.8241 sobre el conjunto de prueba, superando al baseline de Regresión Logística en 3.14 puntos porcentuales. Si bien la mejora puede parecer modesta en términos absolutos, es metodológicamente significativa en un dominio inherentemente ruidoso como la predicción del éxito de startups, donde factores no observables limitan el techo predictivo de cualquier modelo basado solo en variables financieras y estructurales.

El análisis de SHAP confirma que las decisiones del modelo son interpretables y consistentes con la intuición del dominio: las startups con más conexiones, milestones recientes y avance en rondas de funding tienen mayor probabilidad de ser adquiridas. La dominancia del feature **relationships** sugiere que el capital social captura información que las variables puramente financieras no logran reflejar.

Desde la perspectiva de un inversionista, el modelo entrega un desempeño útil pero no infalible. La precisión del 82 % sobre la clase *acquired* implica que aproximadamente 1 de cada 5 startups recomendadas resultará en pérdida de capital, una tasa de error que debe interpretarse como

un complemento al análisis cualitativo, no un reemplazo.

6.2. Limitaciones

- **SMOTE aplicado antes del split de validación cruzada:** las muestras sintéticas generadas pueden distribuirse entre folds de CV, inflando las métricas de validación. Las métricas reportadas sobre el conjunto de prueba son la referencia honesta.
- **Tamaño del dataset:** con solo 954 muestras de entrenamiento y 185 de prueba, los intervalos de confianza sobre las métricas son amplios y limitan la capacidad de tuning agresivo de hiperparámetros sin sobreajustar al ruido.
- **Sesgo de supervivencia:** el dataset incluye startups que recibieron algún tipo de funding, lo que excluye a la mayoría de proyectos que nunca consiguieron inversión inicial. El modelo no generaliza a startups en etapa pre-seed.
- **Variables no observables:** factores críticos como la calidad del equipo, condiciones macroeconómicas o timing de mercado no están presentes en el dataset y representan un techo natural para la predicción.

6.3. Trabajo futuro

- Dos extensiones realistas mejorarían el sistema:
1. **Pipeline correcto de SMOTE dentro de CV:** implementar el balanceo de clases mediante `imblearn.Pipeline` dentro de cada fold de validación cruzada eliminaría el sesgo de inflación de métricas y permitiría un tuning de hiperparámetros más confiable.
 2. **Calibración de probabilidades:** aplicar `CalibratedClassifierCV` sobre el modelo final mejoraría la confiabilidad de las probabilidades emitidas. Esto es especialmente valioso en el contexto de inversión, donde una probabilidad del 70 % debe corresponder empíricamente a una tasa de éxito cercana al 70 %, no a un valor inflado por el desbalance original.

7. Conclusiones

- Este trabajo responde afirmativamente a la pregunta de investigación planteada: el modelo XGBoost alcanzó un AUC-ROC de 0.8241 sobre el conjunto de prueba, superando el umbral objetivo de 0.80 y al baseline de Regresión Logística en 3.14 puntos porcentuales. Los principales hallazgos se sintetizan en cuatro puntos:
1. **Predictibilidad del éxito:** es posible predecir el éxito de una startup con AUC superior a 0.80 usando únicamente variables estructurales de financiación, red de

contactos e hitos, sin requerir información cualitativa del equipo fundador.

2. **Capital social como predictor dominante:** `relationships` es la feature más influyente según SHAP, con un impacto 50 % mayor que el segundo predictor. Esto sugiere que la red de contactos captura señales de calidad empresarial que las variables financieras no reflejan directamente.
3. **Explicabilidad accionable:** la integración de SHAP con un LLM permite transformar predicciones numéricas en recomendaciones comprensibles para inversores no técnicos, cerrando la brecha entre el modelo y el tomador de decisiones.
4. **Limitaciones inherentes al dominio:** con una tasa de falsos positivos del 17.9 %, el sistema debe concebirse como un complemento al análisis cualitativo, no como un oráculo de inversión. Factores no observables como la calidad del equipo o el timing de mercado imponen un techo predictivo que ningún modelo basado en datos estructurales puede superar.

Declaración de uso de IA generativa

Durante el desarrollo de este proyecto se utilizaron herramientas de IA generativa (Claude, Anthropic) como apoyo en las siguientes tareas: estructuración y revisión de código en los notebooks, redacción y edición del informe técnico, y discusión metodológica sobre limitaciones del pipeline.

Todas las decisiones técnicas, ejecución del código, validación de resultados y conclusiones fueron realizadas y verificadas por los autores. La IA se empleó como herramienta de productividad y discusión técnica, no como sustituto del trabajo intelectual del equipo.

Contribuciones del equipo

Integrante	Contribución principal
Juan Esteban Trujillo Montes	Análisis exploratorio de datos (EDA), preprocesamiento, balanceo de clases con SMOTE y visualizaciones para el informe
Andrés Pérez Quinchía	Entrenamiento del modelo XGBoost, ajuste de hiperparámetros, métricas de evaluación y análisis de explicabilidad con SHAP
Sahian Salome Gutiérrez Ossa	Integración del componente LLM (Groq API), construcción de prompts, evaluación cuantitativa de explicaciones y demo interactiva en Streamlit

Distribución de responsabilidades por integrante.

Repositorio y Demo

- **GitHub:** <https://github.com/JuanTrujilloM/startup-success-llm>
- **Video demo (≤3 min):** <https://drive.google.com/file/d/1M2IBgvLNv2Kt8kTV9EgoKDL8IiRVX55Z/view?usp=drivesdk>
- **Instalación:** `pip install -r requirements.txt`
- **Notebook principal:** `notebooks/03_modeling.ipynb`

Referencias

- [1] Chen, T., & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. KDD 2016. <https://arxiv.org/abs/1603.02754>
- [2] Lundberg, S., & Lee, S. (2017). *A Unified Approach to Interpreting Model Predictions*. NeurIPS 2017. <https://arxiv.org/abs/1705.07874>
- [3] Chawla, N., et al. (2002). *SMOTE: Synthetic Minority Over-sampling Technique*. Journal of Artificial Intelligence Research, 16, 321–357. <https://arxiv.org/abs/1106.1813>
- [4] Touvron, H., et al. (2023). *Llama 2: Open Foundation and Fine-Tuned Chat Models*. Meta AI. <https://arxiv.org/abs/2307.09288>
- [5] Kumar, M. (2018). *Startup Success Prediction Dataset*. Kaggle. <https://www.kaggle.com/datasets/manishkc06/startup-success-prediction>

A. Detalles de hiperparámetros y búsqueda

El modelo final utilizado en la aplicación corresponde a un clasificador XGBoost entrenado sobre las variables preprocesadas del conjunto Crunchbase. Los hiperparámetros finales se fijaron a partir de la experimentación realizada en el notebook de modelado y fueron reproducidos mediante el script `scratch/recreate_model.py`.

Cuadro 4: Hiperparámetros del modelo XGBoost final

Hiperparámetro	Valor
<code>n_estimators</code>	200
<code>max_depth</code>	4
<code>learning_rate</code>	0.1
<code>subsample</code>	0.8
<code>colsample_bytree</code>	0.8
<code>reg_alpha</code>	0.1
<code>reg_lambda</code>	1.0
<code>random_state</code>	42
<code>eval_metric</code>	<code>logloss</code>

El conjunto de entrenamiento procesado contiene 954 observaciones y 31 variables predictoras, mientras que el conjunto de prueba contiene 185 observaciones. Las métricas obtenidas sobre el conjunto de prueba fueron las siguientes:

Cuadro 5: Desempeño del modelo final en el conjunto de prueba

Métrica	Valor
AUC-ROC	0.8260
Accuracy	0.7892
Precision	0.8240
Recall	0.8583
F1-score	0.8408

La selección del modelo priorizó un balance entre desempeño predictivo y explicabilidad posterior. XGBoost fue elegido porque permite capturar relaciones no lineales entre variables financieras, operativas y de ecosistema, manteniendo compatibilidad directa con explicaciones locales mediante SHAP (*TreeExplainer*).

B. Ejemplos adicionales de outputs del sistema

Para evaluar la estabilidad del sistema explicativo se seleccionaron tres casos representativos del conjunto de prueba: un caso de éxito con alta confianza, un caso de cierre con alta confianza y un caso fronterizo. Estos casos permiten observar el comportamiento del modelo y del generador de informes en escenarios con distintos niveles de certeza.

Cuadro 6: Casos representativos usados para análisis cualitativo

Caso	Índice	Prob. éxito	Real	Predicción
Éxito – alta confianza	88	0.9966	1	1
Cierre – alta confianza	86	0.0011	0	0
Borderline	133	0.5075	1	1

En cada caso, el sistema genera una predicción probabilística, calcula las contribuciones SHAP locales y produce un informe ejecutivo en lenguaje natural orientado a un analista de capital de riesgo. La estructura del informe contiene: resumen ejecutivo, fortalezas explicadas por SHAP, puntos críticos de alerta y recomendaciones estratégicas.

Cuadro 7: Evaluación cuantitativa de versiones del prompt LLM

Caso	Versión	Veredicto	SHAP	Acción	Estructura	Composite
Éxito alta confianza	v1	1.0	1.0	1.0	1.0	1.000
Éxito alta confianza	v2	1.0	1.0	1.0	1.0	1.000
Éxito alta confianza	v3	1.0	1.0	1.0	1.0	1.000
Cierre alta confianza	v1	1.0	1.0	1.0	1.0	1.000
Cierre alta confianza	v2	1.0	1.0	1.0	1.0	1.000
Cierre alta confianza	v3	1.0	1.0	1.0	1.0	1.000
Borderline	v1	1.0	0.9	1.0	1.0	0.965
Borderline	v2	1.0	1.0	1.0	1.0	1.000
Borderline	v3	1.0	1.0	1.0	1.0	1.000




Figura 7: Resumen global de importancia SHAP sobre el conjunto de prueba.

Adicionalmente, se evaluaron tres versiones del prompt utilizado para generar explicaciones con el LLM. La evaluación consideró alineación del veredicto, mención correcta de factores SHAP, accionabilidad, estructura y una métrica compuesta.

La versión optimizada del prompt mostró mejor consistencia en el caso fronterizo, donde la probabilidad estimada se encuentra cerca del umbral de decisión. Esto sugiere que el enriquecimiento del prompt con instrucciones más explícitas sobre dirección e interpretación de SHAP reduce el riesgo de explicaciones ambiguas.